Отчёт об эксперименте: сравнение retrieval-моделей e5-small и e5-base

Поле	Значение
ID отчёта	RPT-F-2026-11-05-01
Версия	1.0
Дата	2026-11-05
Статус	Final — по результатам завершённой фазы F
Объект	Кандидатский retrieval-контур `e5-base` против живого `e5-small`
Связанные документы	`docs/PLAN_AFTER_E5_BASE.md` v2.5; `data/local_notes/after_e5_base/decision.md`; `noise_pilot.md`; `state.json`; `preflight.md`; `d_bm25.md`; `smoke.md`
Основание	Пользовательское решение о запуске amended-F после FAIL F.0
Автор	AI coding agent (Lead)
Заказчик/владелец данных	владелец проекта `MCP_1C_homework`

Отчёт подготовлен в соответствии с практикой международных стандартов инженерии ПО:

ISO/IEC/IEEE 29119-2/-3 (тестовые процессы и документация), ISO/IEC 25010 (модель качества),

ISO/IEC/IEEE 12207 (жизненный цикл ПО), IEEE 828 (конфигурационный менеджмент),

ISO/IEC/IEEE 15939 (процесс измерения). Формальная сертификация соответствия не заявляется —

стандарты использованы как структура и чек-лист полноты.

---

0. Аннотация (executive summary)

Цель: определить, обосновано ли переключение живого MCP-контура (e5-small, `chroma_xml+bm25_all`) на кандидат (e5-base, `chroma_e5_base+bm25_e5_base`).

Метод: парная офлайн-оценка retrieval на трёх code-наборах (v2 dev, v3/v4 holdout), режимы `vector` и `hybrid`, 4/3/4 и 4/4/4 прогонов на сторону, source-level nDCG@10 как ворота; парный bootstrap 95 % CI и paired t-test; отдельно измерен шум приближённого ANN-поиска.

Результат (vector, nDCG@10, e5-base − e5-small):

- v2: **−0.0664**, CI [−0.1535; +0.0208], p = 0.140;
- v3 code: **−0.0823**, CI [−0.1477; −0.0185], p = 0.017 (значимо хуже);
- v4 code: **+0.0174**, CI [−0.0280; +0.0628], p = 0.460 (неотличимо от нуля).

Вывод: кандидат **не показал преимущества**; правило §F.7 даёт исход **«неразличимо»**, «принять» не выполнено. Переключение MCP не обосновано и **не выполнялось**; фаза G не запускалась.

Ключевой вопрос отчёта: почему более крупная e5-base (278M параметров, dim 768) не лучше e5-small (118M, dim 384) на этой задаче? В §5 разобраны гипотезы: смешение факторов «модель+нарезка» в бандле, деградация exact-name запросов, приближённый ANN, смещение gold/бенчмарка в пользу incumbent, сдвиг BM25-распределения, доменное несоответствие, статистические ограничения. Ни одна из гипотез не подтверждена как единственная причина; для проверки предложены контролируемые эксперименты (§7).

---

1. Введение

1.1. Назначение и контекст

Эксперимент отвечает на вопрос: улучшает ли кандидатский контур качество поиска по коду 1С настолько, чтобы заменить живой контур, не ухудшив функциональность и не создав операционных рисков.

Контекст: ранее был собран полный векторный индекс e5-base (391 427 чанков, dim 768, фаза B/C, ~58 ч CPU). Живой контур использует e5-small (dim 384), символьную нарезку и коллекцию metadata-карточек.

1.2. Область действия (scope)

Входит: офлайн-сравнение качества retrieval на code-запросах, латентность, шум ANN, анализ причин, рекомендации.

Не входит: переключение MCP (фаза G), настройка metadata-коллекций, fine-tuning моделей, BM25-тюнинг, hybrid-веса, оценка XML/BM25-качества, продуктовая приёмка.

1.3. Ссылки

Документ	Роль
`docs/PLAN_AFTER_E5_BASE.md` v2.5	План волны, критерии F/G
`data/local_notes/after_e5_base/decision.md`	Формальное решение F
`data/local_notes/after_e5_base/noise_pilot.md`	Оценка ANN-шума
`data/local_notes/after_e5_base/state.json`	Машиночитаемая фиксация δ, результатов, решения
`data/local_notes/after_e5_base/f0_hnsw.md`	FAIL F.0 и анализ HNSW
`data/local_notes/embedding_e5_base/build.md`	Сборка кандидата
`data/eval/_runs_e5_base/`	23 файла прогонов F

1.4. Термины и сокращения

- **ANN** — approximate nearest neighbours (HNSW в Chroma).
- **nDCG@10** — normalized discounted cumulative gain, cut-off 10; релевантность source-level.
- **CI** — доверительный интервал; **δ** — non-inferiority порог из разброса контроля.
- **Gold-set** — размеченный набор запросов с `relevant_sources`.
- **Control** — живой контур e5-small; **candidate** — кандидат e5-base.
- **F.0** — гейт детерминизма ANN в плане.

---

2. Экспериментальный дизайн

2.1. Исследовательские вопросы и гипотезы

ID	Вопрос/гипотеза	Критерий
RQ1	Улучшает ли candidate nDCG@10 (vector) на code-запросах?	§F.7: accept/reject/inconclusive
RQ2	Меняется ли картина в hybrid?	дополнительно к воротам
RQ3	Какова цена по латентности?	ratio vector ≤ 3×
H0	Разницы нет	формальная проверка CI
H1	Candidate лучше (направленная альтернатива)	lower CI > 0 на всех наборах
H2	Candidate хуже	upper CI < −δ хотя бы на одном
H3	Разница объясняется не моделью, а бандлом (нарезка/коллекции/BM25)	требует ablation (§7)

2.2. Переменные и контроль

- **Независимая переменная (фактически бандл):** контур = модель + нарезка + состав коллекций + BM25-корпус + конфигурация HNSW.
- **Зависимые:** hit@1, MRR@10, nDCG@10, recall@10, latency_ms.
- **Контролируемые:** один корпус, один gold-set SHA, один eval-код, k=10, одинаковые запросы и режимы, одинаковые процессы оценки, фиксированный seed bootstrap, одинаковые пакеты.
- **Не контролируемые полностью:** состояние HNSW (candidate недетерминирован), кэши/прогрев, загрузка машины, порядок прогонов.

2.3. Объекты испытаний (configuration items)

Свойство	Control	Candidate
Chroma	`data/chroma_xml_eval`	`data/chroma_e5_base`
Коллекции (counts)	`code_proc` 154 560; `metadata_xml` 25 026; легаси-пустая `code` 0	`code_proc` 153 990; `config_xml` 237 437
dim	384	768
Модель (HF rev)	`intfloat/multilingual-e5-small` (`614241f6…`)	`intfloat/multilingual-e5-base` (`d1287505…`)
Нарезка	историческая символьная (детали — `docs/HISTORY.md`, в этом эксперименте не перепроверялись)	токенная: `max_tokens=500`, overlap=64, min=32, max_chars=2000
BM25	`data/bm25_all`: 179 586 доков, 85 062 021 Б	`data/bm25_e5_base`: 391 427 доков, 187 881 472 Б
HNSW	персист/детерминирован в наблюдениях	`sync_threshold=1e6`, граф перестраивается из WAL при каждом процессе → недетерминирован

2.4. Наборы данных

Набор	Роль	n (code)	SHA-256 (сверен с D0)
`gold_set_v2.jsonl`	dev (использовался при развитии)	70	`aa0f5a0b…`
`gold_set_v3_holdout.jsonl`	holdout	64 (`--scope code`)	`e14ba5a5…`
`gold_set_v4_holdout.jsonl`	holdout	179 (`--scope code`)	`7d51e90d…`

Другие наборы (`gold_set.jsonl`, `v2_curated.jsonl`, `anchors_v3`, `routing_cases*`, веб-кандидаты) **не использовались** — зафиксировано в `decision.md`.

Состав типов запросов: v2 — exact 4 / semantic 63 / trap 3; v3 code — exact 19 / semantic 26 / trap 19; v4 code — exact 83 / semantic 44 / trap 52.

2.5. Метрики

Метрика	Определение
hit@1	доля запросов, где первый результат — релевантный source
MRR@10	средний обратный ранг первого релевантного
nDCG@10	нормированный DCG@10 при бинарной source-level релевантности (source ∈ `relevant_sources`)
recall@10	доля релевантных sources, попавших в top-10
latency_ms	среднее время поиска на запрос внутри прогретого процесса (без загрузки модели/индекса)

Метрики реализованы в `src/mcp_1c_rag/eval_metrics.py`/`scripts/eval_pipeline.py`; не менялись.

2.6. Протокол

1. Pre-F: сверка SHA gold с D0, чистый out-dir, проверка покрытия gold-источников в `source` обоих контуров (220/220), оценка времени.
2. Прогоны: отдельный процесс на прогон (`run_eval_runs.py`), режимы `hybrid,vector`; control n=4/3/4, candidate n=4/4/4; `k=10`.
3. Метрики: per-query значения усредняются по прогонам, затем парное сравнение old/new по query id.
4. Статистика: paired bootstrap 95 % percentile CI (10 000 resamples, seed 42) + paired t-test; W/T/L по Δ.
5. δ: `max(floor, pstdev контроля)`; floors vector — v2 0.028, v3/v4 0.020; записаны **до** прогонов кандидата.
6. Решение по §F.7 плана.

2.7. Отклонения от плана (ISO/IEC/IEEE 29119-3, deviation report)

Отклонение	Причина	Влияние	Компенсация
F.0 (детерминизм ANN) FAIL	candidate HNSW не персистится (`sync_threshold=1e6`, chroma#7090); пересборка графа hnswlib рандомизирована	первый/каждый прогон candidate — случайная ANN-выборка	amended-F: шум измерен пилотом, candidate n=4; шум записан
candidate n=4 на v3 вместо 3	усиление устойчивости к ANN-шуму	небольшой дисбаланс `n_runs` old/new	допускается `eval_report_pair`; записано
HNSW-persist копия не удалась	pickle-персист ломается (`Error loading hnsw index`); `num_threads=1` не даёт детерминизма	«чистый» повтор F на стабильном ANN невозможен в Chroma 1.5.9	зафиксировано в `f0_hnsw.md`/отчёте; предложен exact-cosine F (§7)

---

3. Конфигурационная база и воспроизводимость (IEEE 828)

Артефакт	Значение/путь
Python	3.14.6

chromadb	1.5.9
sentence-transformers / transformers / torch	6.1.0 / 5.20.1 / 2.14.1+cpu
ОС	Windows, CPU-only (без GPU)
Кандидат: chroma	`data/chroma_e5_base`, 5,54 ГБ; counts 153 990 / 237 437; fingerprint `666213c5…` / `faa8ba9a…`, combined `4fb8c2a7…`
Кандидат: чекпоинты	`data/checkpoints/e5_base_bsl.json`, `e5_base_xml.json`
BM25 кандидата	`data/bm25_e5_base`, 187 881 472 Б, n_docs 391 427
Контроль: chroma	`data/chroma_xml_eval`, counts 154 560 / 25 026 (+ легаси code 0)
Контроль: BM25	`data/bm25_all`, 85 062 021 Б, n_docs 179 586
Прогоны	`data/eval/_runs_e5_base/` — 23 `*_run*.json`
Парные отчёты	`after_e5_base/pair_{v2,v3_code,v4_code}_{vector,hybrid}.{json,md}`
Состояние/δ	`after_e5_base/state.json`
MCP	не изменялся (`cordis.patch.yml` без правок)

Команды прогонов и парных отчётов — в приложении B; инвентаризация — в приложении C.

---

4. Результаты

4.1. Vector (ворота)

Метрика	v2 e5-small	v2 e5-base	v3 code e5-small	v3 code e5-base	v4 code e5-small	v4 code e5-base
hit@1	0.1750 ± 0.006	0.1607 ± 0.016	0.1354 ± 0.007	0.1055 ± 0.013	0.3492 ± 0.010	0.3520 ± 0.013
MRR@10	0.2763 ± 0.007	0.2235 ± 0.019	0.2645 ± 0.011	0.1734 ± 0.006	0.4168 ± 0.008	0.4348 ± 0.008
nDCG@10	**0.3365 ± 0.011**	**0.2701 ± 0.031**	**0.2532 ± 0.013**	**0.1709 ± 0.003**	**0.4461 ± 0.008**	**0.4634 ± 0.008**
recall@10	0.5036 ± 0.018	0.3839 ± 0.053	0.3724 ± 0.030	0.2363 ± 0.006	0.5540 ± 0.013	0.5764 ± 0.006
latency, ms	46.3 ± 0.6	61.5 ± 0.6	50.3 ± 0.3	76.5 ± 0.4	54.2 ± 7.3	73.0 ± 0.6
Набор	**Δ nDCG@10**	**95 % CI**	**p (t)**	**W/T/L**	**Cohen's d**	**δ**
v2	−0.0664	[−0.1535; +0.0208]	0.140	19/24/27	−0.178	0.028
v3 code	−0.0823	[−0.1477; −0.0185]	**0.017**	14/22/28	−0.306	0.020
v4 code	+0.0174	[−0.0280; +0.0628]	0.460	53/70/56	+0.055	0.020

4.2. Hybrid (не ворота)

Метрика	v2 e5-small	v2 e5-base	v3 code e5-small	v3 code e5-base	v4 code e5-small	v4 code e5-base
hit@1	0.2143 ± 0.010	0.2214 ± 0.024	0.1094 ± 0.000	0.1289 ± 0.020	0.4050 ± 0.012	0.4497 ± 0.014
MRR@10	0.3656 ± 0.010	0.3313 ± 0.016	0.2643 ± 0.004	0.2174 ± 0.015	0.5208 ± 0.006	0.5493 ± 0.007
nDCG@10	**0.4381 ± 0.011**	**0.3925 ± 0.015**	**0.2617 ± 0.005**	**0.2098 ± 0.007**	**0.5559 ± 0.005**	**0.5782 ± 0.002**
recall@10	0.6429 ± 0.015	0.5518 ± 0.019	0.3993 ± 0.010	0.2891 ± 0.000	0.6990 ± 0.005	0.7149 ± 0.012
latency, ms	53.6 ± 0.6	74.1 ± 0.4	59.3 ± 0.6	89.9 ± 0.9	60.1 ± 4.3	84.8 ± 0.3

Δ nDCG@10 hybrid: v2 −0.0456 (CI [−0.1075; +0.0185], p=0.167, d=−0.167); v3 −0.0518 (CI [−0.1066; +0.0064], p=0.082, d=−0.221); v4 +0.0223 (CI [−0.0131; +0.0582], p=0.222, d=+0.092).

4.3. Стратификация по типам запросов (vector, nDCG@10)

Набор	Тип (n)	e5-small	e5-base	Δ
v2	exact (4)	0.2500	0.0808	−0.1692
v2	semantic (63)	0.3395	0.2591	−0.0805
v2	trap (3)	0.3876	0.7547	+0.3671
v3 code	exact (19)	0.3082	0.2455	−0.0627
v3 code	semantic (26)	0.2453	0.0985	−0.1468
v3 code	trap (19)	0.2090	0.1953	−0.0137
v4 code	exact (83)	0.5326	0.5731	+0.0405
v4 code	semantic (44)	0.2739	0.2606	−0.0133
v4 code	trap (52)	0.4537	0.4601	+0.0063

Осторожно: в v2 подгруппы exact/trap содержат 4 и 3 запроса — значения нестабильны; использовать только как указание направления, не как вывод.

4.4. Латентность (vector)

Набор	e5-small, ms	e5-base, ms	ratio
v2	46.3	61.5	1.33
v3 code	50.3	76.5	1.52
v4 code	54.2	73.0	1.35

Ворота ≤3× пройдены, но кандидат стабильно медленнее (в основном из-за 768-мерных эмбеддингов и большего индекса).

4.5. Шум ANN у кандидата

- per-run nDCG@10 candidate v2: 0.2876 / 0.2255 / 0.2524 (пилот), в формальной F pstdev 0.0306;
- control v2 pstdev 0.0105; F.0: top-10 candidate меняется между процессами (10/10 позиций), control детерминирован;

- per-query: 50 из 70 запросов идентичны во всех 3 пилотных прогонах — шум локализован в «пограничных» запросах, не систематический bias.

4.6. Формальный исход по §F.7

- «Принять» (lower CI > 0 на всех): **не выполнено**.
- «Отклонить» (upper CI < −δ хотя бы на одном): **не выполнено** (v2 upper +0.0208 > −0.028; v3 upper −0.0185 > −0.020; v4 +0.0628 > −0.020).
- Итог: **«неразличимо»**; фактически candidate не лучше (v2/v3 отрицательные, v3 значимо; v4 +0.017 н.з.).

---

5. Анализ причин: почему более мощная e5-base не лучше

«Более мощная» = больше параметров/размерность, но это не гарантирует лучший retrieval на конкретном домене. Ниже — гипотезы, ранжированные по вероятности/влиянию, с указанием, что подтверждено, а что требует отдельного теста.

H1. Смешение факторов в бандле (высокая вероятность, подтверждено дизайном)

Кандидат отличается от контроля **не только моделью**: другая нарезка (токенная proc/500 ток. vs символьная), другой состав коллекций (`config_xml` vs `metadata_xml`), другой BM25-корпус (391k vs 180k), другое состояние HNSW. Δ в F измеряет **связку**, а не «e5-base vs e5-small». Это прямо зафиксировано в §F.1 плана.

Следствие: нельзя утверждать, что e5-base хуже как модель; можно утверждать, что **данный собранный контур** не лучше живого.

Проверка: ablation 2×2 (§7, E2).

H2. Деградация exact-name запросов (частично подтверждено)

На v2/v3 точные запросы (имена процедур/объектов) у candidate ниже; на v4 exact — выше. v2-подгруппа мала (4 запроса), поэтому вывод осторожный. Возможный механизм: токенная нарезка даёт более длинные чанки (p50 449 токенов против ~311 у BSL), mean-pooling по длинному тексту «размывает» редкий идентификатор; файловый/процедурный префикс тоже занимает часть бюджета.

Проверка: error analysis exact-запросов + chunk-length sensitivity (§7, E3).

H3. Представление чанков и бюджет (не проверено напрямую)

Кандидат режет по процедурам/строкам с бюджетом 500 токенов и overlap 64; контроль — историческим символьным окном. Разные границы → разная вероятность, что нужная строка попадёт в top-10 чанков, и разная концентрация сигнала. При source-level nDCG это может снижать recall@10 (у candidate recall@10 заметно ниже: v2 0.384 vs 0.504; v3 0.236 vs 0.372).

Проверка: сравнение «модель при одинаковой нарезке» (E2).

H4. Приближённый ANN и недетерминизм (частично подтверждено; не основная причина)

Candidate HNSW не персистится: каждый процесс строит случайный граф; top-10 нестабилен, pstdev nDCG 0.031 против 0.011 у контроля. Это добавляет шум и может снижать recall@10 за счёт приближённого поиска. Но эффект v2/v3 больше шума, а на v4 разница в пределах шума — значит ANN не объясняет всё, но и не исключён.

Проверка: exact-cosine F без ANN (§7, E1) — отделит модель/нарезку от приближённого поиска.

H5. Смещение gold/бенчмарка в пользу incumbent (средняя вероятность)

v2 — dev-набор, на котором развивался и тюнился старый контур; ожидаемо благоприятен контролю. v3/v4 — holdout, но их разметка создавалась в том же проекте и могла учитывать структуру старого индекса; v3 дал значимое ухудшение, v4 — около нуля, что говорит о чувствительности к составу запросов.

Проверка: независимый gold-set (веб-кандидаты после валидации), стратификация по типу/сложности, power analysis (§7, E5).

H6. Сдвиг BM25-распределения в hybrid (средняя вероятность)

Hybrid-кандидат использует BM25, обученный на 391k доков (включая сырые XML), против 180k (включая metadata-карточки). IDF, средняя длина документа и словарь меняются; RRF-ранжирование по коду может систематически смещаться, независимо от качества эмбеддингов. Hybrid-результаты кандидата хуже на v2/v3 и чуть лучше на v4 — согласуется с гипотезой сдвига, но не доказывает её.

Проверка: hybrid с BM25-индексом, ограниченным `code_proc` (E4).

H7. Доменное несоответствие и геометрия эмбеддингов (низкая-средняя вероятность, не проверено)

e5-base обучена на общих мультиязычных парах; код 1С и русские идентификаторы — узкий домен. Большая размерность и иная анизотропия косинусного пространства могут менять распределение top-k для коротких/точных запросов; «больше параметров» не равно «лучше на домене». Fine-tuning не проводился.

Проверка: сравнение на общем benchmark (e5-base vs small вне домена), анализ распределения cosine-скоров и margin между top-1/top-10 (E3).

H8. Статистические ограничения (подтверждено как ограничение)

3 набора × 2 режима без поправки на множественные сравнения; часть подгрупп мала (v2 exact=4, trap=3); CI широкие; v3-эффект значим по t-тесту, но не выходит за δ-маржу. «Не лучше» — устойчивый вывод; «хуже» — уверенно только для v3.

---

6. Валидность и ограничения (ISO/IEC/IEEE 29119-3, ISO/IEC 25010)

Тип валидности	Угроза	Митигация/статус
Construct	source-level метрики не отражают полезность ответа агенту; nDCG при бинарной релевантности	метрики стандартные, зафиксированы; рекомендуется дополнить human/LLM-judge оценкой
Internal	смешение модель+нарезка+BM25+HNSW; разное число прогонов; ANN-недетерминизм	F.1 фиксирует; amended-F измеряет шум; ablation предложен
External	одна конфигурация 1С, один язык, одна машина, CPU-only	вывод ограничен этим корпусом; не генерализовать на все 1С
Conclusion	множественные сравнения, малые подгруппы, широкие CI	δ-маржи, bootstrap, W/T/L; вывод «не лучше» устойчив, «хуже» — только v3
Reliability	HNSW-пересборка, кэши, фоновая нагрузка	отдельные процессы, фиксированные seed/наборы, артефакты сохранены
Reproducibility	HNSW candidate недетерминирован	задокументировано; exact-cosine F снимет этот фактор

---

7. Выводы и рекомендации

7.1. Выводы

7. Кандидат e5-base **не превосходит** живой e5-small на code-запросах в измеренных условиях; на v2/v3 — хуже (v3 значимо), на v4 — в пределах шума.
8. Формальный исход §F.7 — **«неразличимо»**; «принять» не выполнено.
9. Переключение MCP **не обосновано**; G не выполнялась, живой контур сохранён.
10. Причина «мощнее, но слабее» **не установлена однозначно**: главный кандидат — смешение факторов бандла (H1), далее exact-name/нарезка (H2–H3), ANN-шум (H4), смещение gold (H5), сдвиг BM25 (H6). Утверждение «e5-base хуже как модель» **не доказано**.
11. Операционные риски кандидата (недетерминированный HNSW, +33–52 % латентности, отсутствие metadata-коллекции) дополнительно снижают целесообразность переключения.

7.2. Рекомендации (приоритет)

ID	Действие	Цель	Оценка
E1	exact-cosine F: выгрузить эмбеддинги, top-10 точным косинусом, тот же gold/CI	отделить качество модели/нарезки от ANN	1–2 ч, без изменения индекса

E2	ablation 2×2: e5-small/e5-base × символьная/токенная нарезка	развязать модель и нарезку	дорого: 2 доп. индекса
E3	error analysis: exact-запросы, длина чанка, margin top-1/top-10, косинусные распределения	объяснить деградацию exact	2–4 ч
E4	hybrid с BM25 только по `code_proc`	проверить H6	1–2 ч
E5	независимый gold-set (валидированные веб-кандидаты), power analysis	снизить H5, повысить мощность	по отдельному плану
E6	Chroma upgrade/патч персиста HNSW	снять H4 и операционный риск	отдельный мини-план

Критерий будущего переключения (G): F=accept (CI lower > 0 на всех code-наборах) **или** письменно принятая non-inferiority; стабильный ANN; решение по metadata (G1/G2/G3); latency ≤ согласованного порога; backup+rollback проверены.

7.3. Что делать сейчас

- Оставить MCP на старом контуре.
- Зафиксировать отчёт/decision в `docs/INDEX.md` (документальная фаза).
- Кандидатские артефакты сохранить как baseline для E1–E4; удаление — только по явной команде.

---

8. Соответствие стандартам (tailoring)

Раздел отчёта	**ISO/IEC/IEEE 29119-3 (test report)**	**ISO/IEC 25010**	**ISO/IEC/IEEE 12207**	**Прочее**
0–1	Context, scope, references	—	Lifecycle context	—
2	Test design, items, deviations	Functional suitability (метрики)	Verification planning	Wohlin et al. (experiment design)
3	Configuration baseline	—	Configuration management	IEEE 828
4	Results, metrics	Functional correctness, performance efficiency (time behavior)	Verification results	ISO/IEC/IEEE 15939 (measurement)
5	Analysis	Functional suitability, reliability (ANN)	Validation analysis	—
6	Risks/validity	Reliability, maintainability (operability)	Quality assurance	Threats-to-validity taxonomy
7	Conclusions/ recommendations	—	Improvement	—
Annex	Traceability/evidence	—	Information management	—

Приложение A. Окружение

- Python 3.14.6; chromadb 1.5.9; sentence-transformers 6.1.0; transformers 5.20.1; torch 2.14.1+cpu.
- Windows, CPU-only, 15,7 ГБ RAM; интерпретатор `D:\MCP_1C_homework\.venv\Scripts\python.exe`.
- Модели: e5-small rev `614241f622f53c4eeff9890bdc4f31cfecc418b3`; e5-base rev `d128750597153bb5987e10b1c3493a34e5a4502a`.

Приложение B. Команды

Контроль (e5-small):

```
py scripts/run_eval_runs.py --golden data/eval/gold_set_v2.jsonl --chroma-dir data/chroma_xml_eval --bm25-dir data/bm25_all
--collection code_proc --embedding-model intfloat/multilingual-e5-small --modes hybrid,vector --n-runs 4 --prefix old_v2 --
out-dir data/eval/_runs_e5_base
py scripts/run_eval_runs.py --golden data/eval/gold_set_v3_holdout.jsonl --chroma-dir data/chroma_xml_eval --bm25-dir
data/bm25_all --collection code_proc --embedding-model intfloat/multilingual-e5-small --modes hybrid,vector --scope code --
n-runs 3 --prefix old_v3_code --out-dir data/eval/_runs_e5_base
py scripts/run_eval_runs.py --golden data/eval/gold_set_v4_holdout.jsonl --chroma-dir data/chroma_xml_eval --bm25-dir
data/bm25_all --collection code_proc --embedding-model intfloat/multilingual-e5-small --modes hybrid,vector --scope code --
n-runs 4 --prefix old_v4_code --out-dir data/eval/_runs_e5_base
```

Кандидат (e5-base): те же команды с `--chroma-dir data/chroma_e5_base --bm25-dir data/bm25_e5_base --embedding-model intfloat/multilingual-e5-base --n-runs 4 --prefix new_v2/new_v3_code/new_v4_code`.

δ и пары:

```
py scripts/record_control_delta.py --runs "data/eval/_runs_e5_base/old_v2_run*.json" --mode vector --metric ndcg@10 --floor
0.028 --key delta_v2 --state data/local_notes/after_e5_base/state.json
py scripts/eval_report_pair.py --old "data/eval/_runs_e5_base/old_v2_run*.json" --new
"data/eval/_runs_e5_base/new_v2_run*.json" --mode vector --metric ndcg@10 --out-json
data/local_notes/after_e5_base/pair_v2_vector.json --out-md data/local_notes/after_e5_base/pair_v2_vector.md
```

(аналогично v3_code/v4_code и hybrid).

Приложение C. Инвентаризация артефактов

Артефакт	**Путь**
decision	`data/local_notes/after_e5_base/decision.md`
state	`data/local_notes/after_e5_base/state.json`
noise pilot	`after_e5_base/noise_pilot.md`, `pilot_v*_vector.*`
F.0	`after_e5_base/f0_hnsw.md`, `f0_stability.py`, `f0_stab_*.json`
пары	`after_e5_base/pair_{v2,v3_code,v4_code}_{vector,hybrid}.{json,md}`
прогоны	`data/eval/_runs_e5_base/` (23 файла)
prechecks	`after_e5_base/check_gold_sources.py`, `latency_ratio.py`
логи	`after_e5_base/f_control.log`, `f_candidate.log`

Приложение D. Инвентаризация прогонов

`data/eval/_runs_e5_base/`: `old_v2_run1..4.json` (4), `old_v3_code_run1..3.json` (3), `old_v4_code_run1..4.json` (4), `new_v2_run1..4.json` (4), `new_v3_code_run1..4.json` (4), `new_v4_code_run1..4.json` (4) — итого 23.

Приложение E. Определения метрик (сокращённо)

- DCG@10 = Σ rel_i / log2(i+1); nDCG@10 = DCG@10 / IDCG@10; rel_i ∈ {0,1} по попаданию source в `relevant_sources`.
- MRR@10 = 1 / rank первого релевантного (0, если нет).
- recall@10 = |retrieved_sources ∩ relevant_sources| / |relevant_sources|.
- Δ = new − old; CI — percentile bootstrap 95 % (10 000, seed 42); p — paired t-test; Cohen's d = mean(Δ_query) / sd(Δ_query).

Приложение F. Источники

- `docs/PLAN_AFTER_E5_BASE.md` v2.5; `docs/PLAN_EMBEDDING_E5_BASE.md`; `docs/HISTORY.md`; `docs/EVALUATION.md`.
- `data/local_notes/after_e5_base/` (decision, noise_pilot, f0_hnsw, state, preflight).
- ISO/IEC/IEEE 29119-2:2013, 29119-3:2013; ISO/IEC 25010:2011; ISO/IEC/IEEE 12207:2017; IEEE 828-2012; ISO/IEC/IEEE 15939:2017; Wohlin et al., Experimentation in Software Engineering (2012).